

# BI-PST homework

December 19, 2018

## 1 case0222 - Cholesterol In Urban And Rural Guatemalans

<https://www.rdocumentation.org/packages/Sleuth2/versions/2.0-4/topics/ex0222>

### 1.1 Vypracovali (všichni cvičení st 14:30)

- Matyáš Skalický (skalimat)
- Martin Vastl (vastlmar)
- Matej Choma (chomamat)

### 1.2 Popis dat

Dataset pochází ze studie provedené na guatemalských indiánech. Míra cholesterolu byla změřena celkem 94 jedincům a byl zaznamenán jejich původ. Bylo naměřeno 49 pozorování na venkově a 45 ve městě.

### 1.3 Formát

Dataframe obsahuje 94 pozorování na následujících 2 proměnných:

- **Cholesterol** - Množství cholesterolu v krvi člověka (v mg/l).
- **Group** - Proměnná obsahující hodnoty "Rural" a "Urban" označující, jestli je subjekt z venkova, nebo z města.

### 1.4 Zdroj

Ramsey, F.L. and Schafer, D.W. (2002). The Statistical Sleuth: A Course in Methods of Data Analysis (2nd ed), Duxbury.

```
In [1]: library(Sleuth2)
        str(ex0222)
```

```
'data.frame':  94 obs. of  2 variables:
 $ Cholesterol: num  133 134 155 170 175 179 181 184 188 189 ...
 $ Group      : Factor w/ 2 levels "Rural","Urban": 2 2 2 2 2 2 2 2 2 2 ...
```

## 2 Úkoly

### 2.1 Úkol 1

(1b) Načtěte datový soubor a rozdělte sledovanou proměnnou na příslušné dvě pozorované skupiny. Data stručně popište. Pro každou skupinu zvlášť odhadněte střední hodnotu, rozptyl a medián příslušného rozdělení.

```
In [2]: rural <- subset(ex0222, Group=="Rural", Cholesterol, drop=TRUE)
        urban <- subset(ex0222, Group=="Urban", Cholesterol, drop=TRUE)
```

#### 2.1.1 Subjekty z venkova:

```
In [3]: cat("Rural area indians:\n")
        cat("ER =", mean(rural), "\n")
        cat("varR =", var(rural), "\n")
        cat("median =", median(rural))
```

```
Rural area indians:
ER = 157
varR = 1008.458
median = 152
```

#### 2.1.2 Subjekty z města:

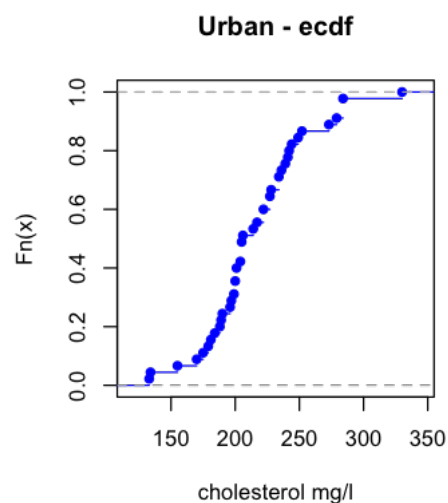
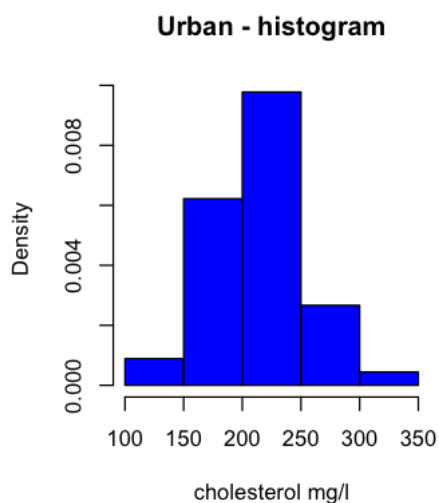


```
In [4]: cat("Urban area indians:\n")
        cat("EU =", mean(urban), "\n")
        cat("varU =", var(urban), "\n")
        cat("median =", median(urban))
```

```
Urban area indians:
EU = 216.8667
varU = 1593.618
median = 206
```

## 2.2 Úkol 2

(1b) Pro každou skupinu zvlášť odhadněte hustotu a distribuční funkci pomocí histogramu a empirické distribuční funkce.

```
In [6]: par(mfrow = c(2, 2), pty="s")
# rural
hist(rural, col="red", main="Rural - histogram", probability=T,
     xlab="cholesterol mg/l")
plot.ecdf(rural, col="red", main="Rural - ecdf", xlab="cholesterol mg/l")
# urban
hist(urban, col="blue", main = "Urban - histogram", probability=T,
     xlab="cholesterol mg/l")
plot.ecdf(urban, col="blue", main="Urban - ecdf", xlab="cholesterol mg/l")
```



## 2.3 Úkol 3

(3b) Pro každou skupinu zvlášť najděte nejbližší rozdělení: Odhadněte parametry normálního, exponenciálního a rovnoměrného rozdělení. Zaneste příslušné hustoty s odhadnutými parametry do grafů histogramu. Diskutujte, které z rozdělení odpovídá pozorovaným datům nejlépe.

### Odhady rozdělení

Pro provedení odhadu jsou využity funkce *mean()* a *sd()* zabudované do standardní knihovny jazyka R. Odhad je proveden shodně i pro množinu urban.

Pro odhad normálního a exponenciálního rozdělení jsme využili momentovou metodu. Pro odhad uniformního rozdělení metodu maximální věrohodnosti.

#### Normální rozdělení

```
EX = mean(rural)
s = sd(rural)
```

#### Exponenciální rozdělení

```
lambda = 1/mean(rural)
```

#### Uniformní rozdělení

```
a = min(rural)
b = max(rural)
```

```

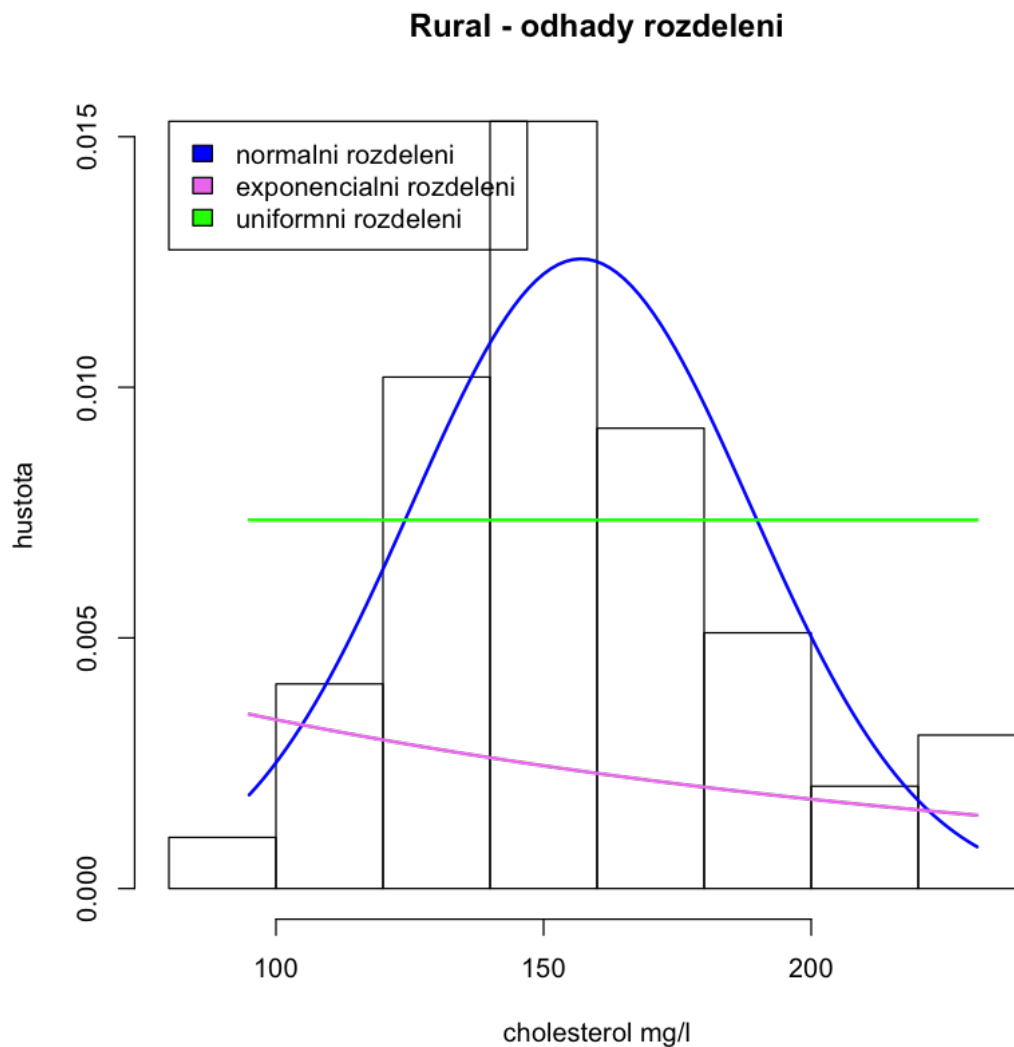
In [10]: x <- seq(min(rural), max(rural), length=100)

# hodnoty pro jednotlivá rozložení
y_norm <- dnorm(x, mean=mean(rural), sd=sd(rural))
y_exp <- dexp(x, 1/mean(rural))
y_unif <- dunif(x, min=min(rural), max=max(rural))

hist(rural, probability=T, main="Rural - odhady rozdeleni", xlab="cholesterol mg/l",
     ylab="hustota")
lines(x, y_norm, col="blue", lwd=2)
lines(x, y_exp, col="violet", lwd=2)
lines(x, y_unif, col="green", lwd=2)

legend("topleft", inset=0.037, fill=c("blue","violet","green"),
      legend=c("normalni rozdeleni", "exponencialni rozdeleni",
               "uniformni rozdeleni"))

```



```

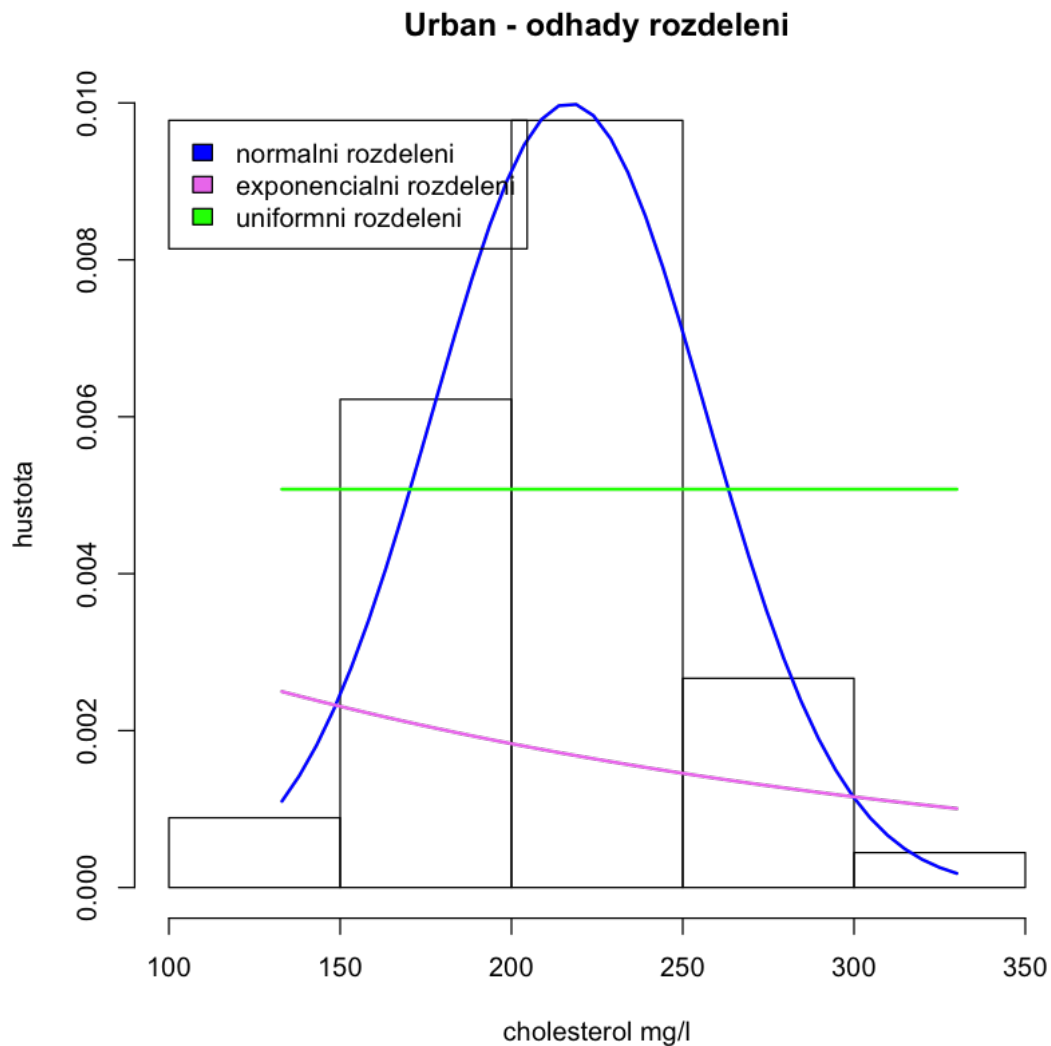
In [9]: x <- seq(min(urban), max(urban), length=40)

y_norm <- dnorm(x, mean=mean(urban), sd=sd(urban))
y_exp <- dexp(x, 1/mean(urban))
y_unif <- dunif(x, min=min(urban), max=max(urban))

hist(urban, probability=T, main="Urban - odhady rozdeleni", xlab="cholesterol mg/l",
     ylab="hustota")
lines(x, y_norm, col="blue", lwd=2)
lines(x, y_exp, col="violet", lwd=2)
lines(x, y_unif, col="green", lwd=2)

legend("topleft", inset=0.037, fill=c("blue","violet","green"),
      legend=c("normalni rozdeleni", "exponencialni rozdeleni",
               "uniformni rozdeleni"))

```



## 2.4 Úkol 4

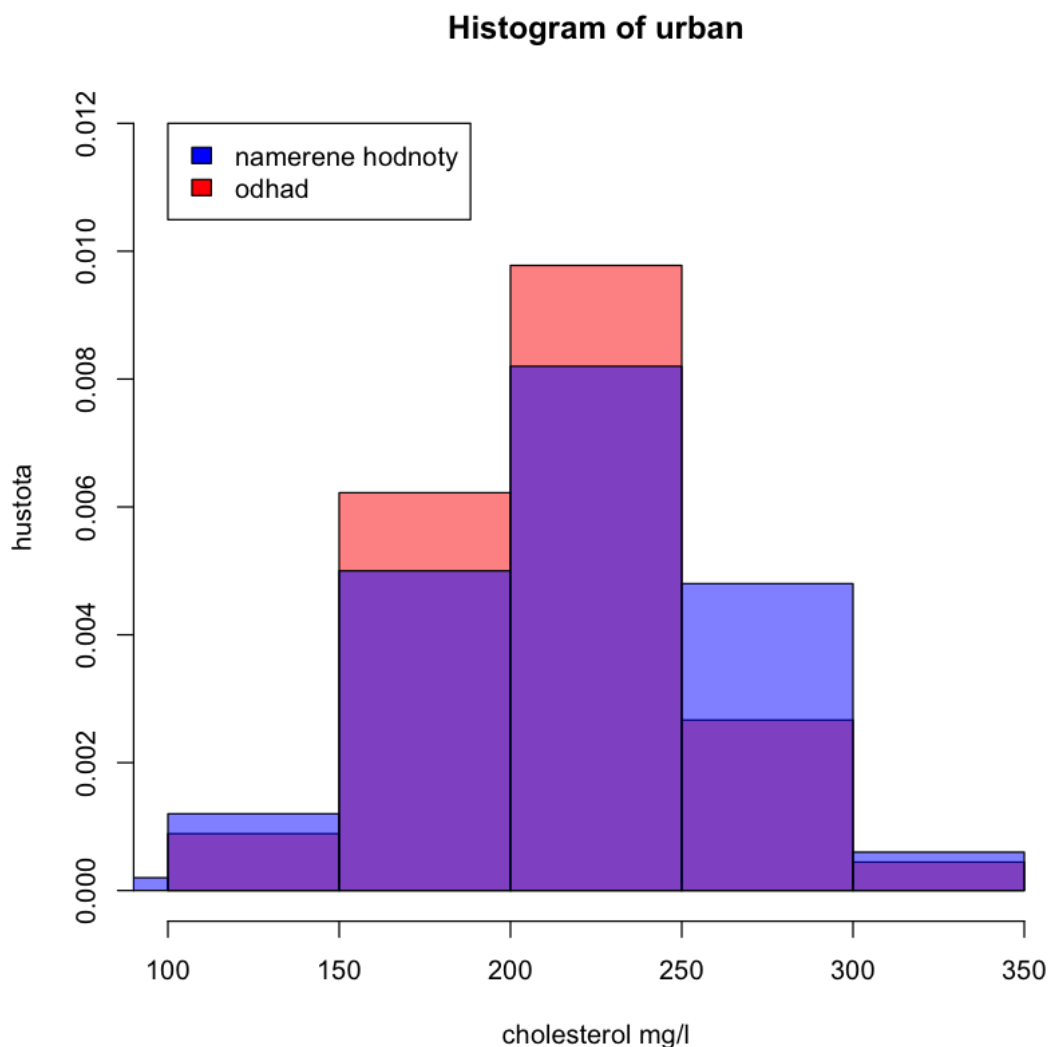
(1b) Pro každou skupinu zvlášť vygenerujte náhodný výběr o 100 hodnotách z rozdělení, které jste zvolili jako nejbližší, s parametry odhadnutými v předchozím bodě. Porovnejte histogram simulovaných hodnot s pozorovanými daty.

Na náš dataset se nejvíc hodí normální rozdělení. Parametry jsme odhadli pomocí knihovnických funkcí `mean()` a `sd()`. Samotný náhodný výběr jsme vygenerovali následujícím příkazem:

```
rnorm(100, mean=mean(urban), sd=sd(urban))
```


```
In [14]: y <- rnorm(100, mean=mean(urban), sd=sd(urban))
```

```
hist(urban, probability=T, col=rgb(1, 0, 0, 0.5), ylim=c(0, 0.012),  
     xlab="cholesterol mg/l", ylab="hustota", breaks=6)  
hist(y, probability=T, col=rgb(0, 0, 1, 0.5), add=T, breaks=6)  
legend("topleft", inset=0.037, fill=c("blue","red"),  
       legend=c("namerene hodnoty", "odhad"))
```



```
In [20]: y <- rnorm(100, mean=mean(rural), sd=sd(rural))

hist(rural, probability=T, col=rgb(1, 0, 0, 0.5),
     xlab="cholesterol mg/l", ylab="hustota", breaks=6)
hist(y, probability=T, col=rgb(0, 0, 1, 0.5), add=T, breaks=6)
legend("topleft", inset=0.037, fill=c("blue","red"),
     legend=c("namerene hodnoty", "odhad"))
```





## 2.5 Úkol 5

(1b) Pro každou skupinu zvlášť spočítejte oboustranný 95% konfidenční interval pro střední hodnotu.

```
In [5]: EU <- mean(urban)
        s <- sd(urban)
        n <- length(urban)
        error <- qt(0.975, df=n-1)*s/sqrt(n)
        left <- EU-error
        right <- EU+error

        cat("oboustranný 95% konfidenční interval pro střední hodnotu urban:\n")
        cat("(",left, ", ", right, ")\n")
```

oboustranný 95% konfidenční interval pro střední hodnotu urban:  
( 204.8733 , 228.86 )

```
In [6]: ER <- mean(rural)
        s <- sd(rural)
        n <- length(rural)
        error <- qt(0.975, df=n-1)*s/sqrt(n)
        left <- ER-error
        right <- ER+error

        cat("oboustranný 95% konfidenční interval pro střední hodnotu rural:\n")
        cat("(",left, ", ", right, ")\n")
```

oboustranný 95% konfidenční interval pro střední hodnotu rural:  
( 147.8785 , 166.1215 )

## 2.6 Úkol 6

(1b) Pro každou skupinu zvlášť otestujte na hladině významnosti 5% hypotézu, zda je střední hodnota rovná hodnotě  $K$  (parametr úlohy), proti oboustranné alternativě. Můžete použít buď výsledek z předešlého bodu, nebo výstup z příslušné vestavěné funkce vašeho softwaru.

```
In [23]: alternative <- "two.sided"
         K_parameter <- 2
         conf_level <- 0.95
         t.test(urban, mu=K_parameter, alternative=alternative, conf.level = conf_level)
         t.test(rural, mu=K_parameter, alternative=alternative, conf.level = conf_level)
```

One Sample t-test

```
data: urban
t = 36.106, df = 44, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 2
95 percent confidence interval:
 204.8733 228.8600
sample estimates:
mean of x
 216.8667
```

One Sample t-test

```
data: rural
t = 34.167, df = 48, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 2
95 percent confidence interval:
 147.8785 166.1215
sample estimates:
mean of x
 157
```

**Rural:** Testovaná hodnota  $ER = K = 2$  v intervalu neleží, takže můžeme hypotézu vyváženosti na hladině významnosti 5% zamítnout ve prospěch alternativy, že je pravděpodobnost, že  $ER = 2$  je významně odlišná.

**Urban:** Testovaná hodnota  $EU = K = 2$  v intervalu neleží, takže můžeme hypotézu vyváženosti na hladině významnosti 5% zamítnout ve prospěch alternativy, že je pravděpodobnost, že  $EU = 2$  je významně odlišná.

## 2.7 Úkol 7

(2b) Na hladině spolehlivosti 5% otestujte, jestli mají pozorované skupiny stejnou střední hodnotu. Typ testu a alternativy stanovte tak, aby vaše volba nejlépe korespondovala s povahou zkoumaného problému.

Z povahy testovaných skupin můžeme předpokládat, že střední hodnota cholesterolu u indiánů žijících ve městě bude vyšší, než u těch žijících na venkově. Proto vybíráme alternativní hypotézu  $H_A : EU > ER$

```
In [9]: EU <- mean(urban)
        ER <- mean(rural)
        n <- length(urban)

        error <- qt(0.95, df=n-1)*s/sqrt(n)

        cat("Střední hodnota pro urban EU =",EU,"\n")
        cat("Střední hodnota pro rural ER =",ER,"\n")
        cat("Spodní hranice jednostranného konfidenčního intervalu pro EU je:",EU-error,"\n")
```

Střední hodnota pro urban EU = 216.8667

Střední hodnota pro rural ER = 157

Spodní hranice jednostranného konfidenčního intervalu pro EU je: 208.9126

Testujeme hypotézu  $H_0 : EU = ER$  proti alternativě  $H_A : EU > ER$ . Jednostranný 95% konfidenční interval pro EU je  $(208,9126, +\infty)$ . Střední hodnota ER = 157 je menší než dolní hranice intervalu 208,9126. Hypotézu  $H_0$  na hladině významnosti 5% můžeme tedy zamítnout ve prospěch alternativy  $EU > ER$ .